

# Proposta de Projeto: Análise Comparativa de Métodos de Extração de Características para Busca por Similaridade Visual no Dataset HAM10000

## Resumo Executivo

Este projeto propõe uma análise comparativa de três métodos de extração de vetores de características para busca por similaridade visual no dataset HAM10000, com foco em imagens dermatoscópicas. O objetivo é avaliar a eficácia e o desempenho computacional de técnicas de complexidade crescente — desde uma abordagem simples baseada em cor média até uma solução avançada de deep learning — combinadas com algoritmos de ordenação. O estudo visa identificar os trade-offs entre custo computacional, simplicidade de implementação e relevância semântica dos resultados, fornecendo insights valiosos para aplicações em dermatologia assistida por inteligência artificial.

## 1 Objetivo Técnico

Desenvolver e comparar três técnicas de geração de vetores de características para medir similaridade visual no dataset HAM10000, avaliando:

- **Eficácia:** Qualidade semântica dos resultados de busca por similaridade.
- **Desempenho:** Custo computacional (tempo de extração e ordenação).
- **Escalabilidade:** Viabilidade para datasets de grande escala.

As técnicas serão integradas a algoritmos de ordenação para organizar o dataset com base em uma imagem de referência, produzindo uma análise detalhada dos trade-offs.

## 2 Escopo e Metodologia

O projeto está estruturado em duas etapas principais:

### 2.1 Etapa 1: Extração de Vetores de Características

Três técnicas serão implementadas para extrair vetores de características:

1. **Técnica 1: Cor Média (Baseline)**

- *Descrição*: Método simples que captura a tonalidade média da imagem.
- *Processo*: Calcula os valores médios dos canais RGB.
- *Saída*: Vetor de 3 dimensões:  $[R_{\text{médio}}, G_{\text{médio}}, B_{\text{médio}}]$ .
- *Complexidade*:  $O(n)$ , onde  $n$  é o número de pixels.

## 2. Técnica 2: Segmentação com K-Means

- *Descrição*: Abordagem intermediária que segmenta a lesão do fundo da pele.
- *Processo*:
  - (a) Aplica K-Means ( $k = 2$  ou  $k = 3$ ) para agrupar pixels por cor.
  - (b) Identifica o cluster da lesão (baseado em escuridão/centralidade).
  - (c) Gera uma máscara binária da lesão.
  - (d) Calcula a cor média e a área relativa da lesão.
- *Saída*: Vetor de 4 dimensões:  $[R_{\text{lesão}}, G_{\text{lesão}}, B_{\text{lesão}}, \text{Área}_{\text{relativa}}]$ .
- *Complexidade*:  $O(n \cdot i \cdot k)$ , onde  $i$  é o número de iterações do K-Means.

## 3. Técnica 3: Deep Learning com CNN Pré-Treinada

- *Descrição*: Abordagem avançada que utiliza conhecimento semântico de redes neurais profundas.
- *Processo*:
  - (a) Carrega uma CNN pré-treinada (e.g., ResNet50 ou MobileNetV2) no dataset ImageNet.
  - (b) Remove a camada de classificação final.
  - (c) Extrai características da penúltima camada durante inferência.
- *Saída*: Vetor de alta dimensão (e.g., 2048 para ResNet50).
- *Complexidade*: Depende da arquitetura da CNN, geralmente  $O(n \cdot d)$ , onde  $d$  é a dimensionalidade da camada.

## 2.2 Etapa 2: Similaridade, Ordenação e Análise de Performance

- **Entrada**: Imagem de referência  $I_{\text{ref}}$ , dataset  $D$ , e vetores de características.
- **Processo**:
  1. Calcular scores de similaridade:
    - Técnicas 1 e 2: Distância Euclidiana.
    - Técnica 3: Similaridade de Cosseno.
  2. Ordenar os scores usando:
    - Insertion Sort ( $O(n^2)$ ).
    - Quick Sort ( $O(n \log n)$  em média).

3. Medir:
  - $T_{\text{extração}}$ : Tempo total para gerar vetores de características.
  - $T_{\text{ordenação}}$ : Tempo de execução de cada algoritmo de ordenação.
- **Saída:** Lista ordenada de IDs das imagens (da mais similar à menos similar) e relatório de performance.

### 3 Entregáveis

#### 1. Código-Fonte:

- Repositório Git com código em Python, modular, comentado e estruturado.
- Módulos: Extração de características (Técnicas 1, 2 e 3), ordenação e visualização.

#### 2. Relatório Técnico (PDF, máx. 7 páginas):

- *Introdução:* Contexto do problema e objetivos.
- *Metodologia:* Detalhamento técnico das técnicas e algoritmos.
- *Resultados e Análise:*
  - Tabelas/gráficos comparando  $T_{\text{extração}}$  e  $T_{\text{ordenação}}$ .
  - Análise da complexidade teórica (Big-O) vs. prática.
  - Visualização das 5 imagens mais similares por técnica, com discussão sobre relevância semântica.
- *Conclusão:* Síntese dos trade-offs entre simplicidade, custo e qualidade.

### 4 Critérios de Avaliação

- **Funcionalidade:** Implementação correta de todas as técnicas e algoritmos.
- **Análise Comparativa:** Clareza e profundidade na análise de desempenho e resultados.
- **Qualidade do Código:** Organização, modularidade e documentação.
- **Relevância dos Resultados:** Discussão crítica sobre a eficácia semântica das técnicas.

### 5 Impacto Esperado

Este projeto contribuirá para o avanço de sistemas de busca por similaridade visual em imagens médicas, com aplicações potenciais em triagem dermatológica assistida por IA. A análise comparativa oferecerá insights sobre a viabilidade de diferentes abordagens, equilibrando precisão e eficiência, e pavimentará o caminho para soluções escaláveis em diagnósticos visuais.